Alejandro Burgueño Díaz. 19/08/2021

DETECCIÓN DE FRAUDE

In [5]:
```
# Se cargan las librerías generales
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
import seaborn as sb
```

In [2]:
```
archivo = "credit_card_transactions-ibm_v2.csv"

# Como es un dataset muy pesado se selecciona un número determinado de filas.
# Podría ser selección aleatoria, pero se ha comprobado que es difícil obtener casos de No Fraude (hay pocos casos).
# En su lugar se selecciona una fila cada 2500 de manera regular.
n = 2500
num_lines = sum(1 for l in open(archivo))

# Las filas a evitar. Es preciso mantener la fila 0 del encabezado.
skip_idx = [x for x in range(1, num_lines) if x % n != 0]

# Cargar el dataset reducido
data = pd.read_csv(archivo, skiprows=skip_idx)
```

In [3]:
```
# Se analizan los datos y las frecuencias de aparición
data
```

Out[3]:

	User	Card	Year	Month	Day	Time	Amount	Use Chip	Merchant Name	Merchant City	Merchant State	Zip	MCC	Errors?	Is Fraud?
0	0	0	2010	2	11	07:21	$45.30	Swipe Transaction	-34551508091458520	La Verne	CA	91750.0	5912	NaN	No
1	0	0	2020	1	31	12:42	$73.42	Chip Transaction	-7146670748125200898	Monterey Park	CA	91755.0	5970	NaN	No
2	0	2	2007	10	31	20:00	$61.52	Swipe Transaction	-4500542936415012428	La Verne	CA	91750.0	5814	NaN	No
3	0	2	2017	6	25	20:26	$82.07	Chip Transaction	7069584154815291371	Palo Alto	CA	94301.0	5812	NaN	No
4	0	3	2006	8	4	06:00	$118.59	Swipe Transaction	-34551508091458520	La Verne	CA	91750.0	5912	NaN	No
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
9749	1997	2	2015	6	3	05:44	$3.72	Chip Transaction	-5162038175624867091	Elizabeth	NJ	7201.0	5541	NaN	No
9750	1998	0	2013	10	31	22:50	$85.27	Swipe Transaction	6661973303171003879	Elizabethville	PA	17023.0	5211	NaN	No
9751	1998	0	2017	4	6	14:53	$18.39	Swipe Transaction	6098563624419731578	Lebanon	PA	17042.0	4214	NaN	No
9752	1999	1	2017	6	27	19:11	$49.97	Online Transaction	-6160036380778658394	ONLINE	NaN	NaN	4121	NaN	No
9753	1999	1	2018	12	16	07:42	$50.87	Chip Transaction	2500998799892805156	Merrimack	NH	3054.0	4121	NaN	No

9754 rows × 15 columns

In [4]:
```
for column in data:
    print("---------" + column + "---------")
    print(data[column].value_counts())
```

```
---------User---------
486     33
396     32
332     28
262     27
1150    26
        ..
722      1
1670     1
839      1
738      1
1648     1
Name: User, Length: 1600, dtype: int64
---------Card---------
0    3471
1    2608
2    1722
3    1105
4     527
5     221
```

OBSERVACIONES:

- Aunque la selección de filas es válida para el estudio ya que el porcentaje de 'es fraude'-'no es fraude' se mantiene (9741 frente a 13), siguen siendo pocos casos de 'no es fraude' para entrenar el modelo.
- Puede ser preciso codificar algunos valores en numéricos o binarios para poder ser tratados más fácilmente (por ejemplo, use chip).

ESTUDIO SOBRE MÁS CANTIDAD DE FILAS

Como la cantidad de fraudes encontrados es muy baja, se procura trabajar con datasets mayores hasta encontrar una proporción más adecuada

In [75]:
```
# Repetimos el proceso anterior pero con saltos menores
archivo = "credit_card_transactions-ibm_v2.csv"
n = 1000
num_lines = sum(1 for l in open(archivo))
skip_idx = [x for x in range(1, num_lines) if x % n != 0]
big_data = pd.read_csv(archivo, skiprows=skip_idx)
```

In [76]:
```
big_data['Is Fraud?'].value_counts()
```

Out[76]:
```
No     24353
Yes       33
Name: Is Fraud?, dtype: int64
```

In [21]:
```
# Repetimos el proceso anterior pero con saltos aún menores
archivo = "credit_card_transactions-ibm_v2.csv"
n = 10
num_lines = sum(1 for l in open(archivo))
skip_idx = [x for x in range(1, num_lines) if x % n != 0]
huge_data = pd.read_csv(archivo, skiprows=skip_idx)
```

In [23]:
```
huge_data['Is Fraud?'].value_counts()
```

Out[23]:
```
No     2435757
Yes       2933
Name: Is Fraud?, dtype: int64
```

In [24]:
```
# Finalmente cargamos todo el dataset
whole_data = pd.read_csv(archivo)
```

In [26]:
```
whole_data['Is Fraud?'].value_counts()
```

Out[26]:
```
No     24357143
Yes       29757
Name: Is Fraud?, dtype: int64
```

In [28]:
```
# Se extraen todas las filas de casos de fraude y las guardamos como csv para trabajar cómodamente en el futuro
fraud_data = whole_data.loc[whole_data['Is Fraud?'] == 'Yes']
fraud_data .to_csv('fraud_data.csv')
```

CONJUNTO DE DATOS SELECCIONADO

Para tener un conjunto de datos sostenible y equilibrado, se cruzan todos los casos fraudulentos con uno de los conjuntos de datos expuestos previamente.

In [77]:
```
# El dataframe original de data resulta pequeño en comparación con los fraudes
# Para resolverlo se usa el conjunto Big_Data (más de 240000 casos) y se une con fraud_data (casi 30000 casos)
data = big_data
data = data.loc[data['Is Fraud?'] == 'No']
data = data.append(fraud_data)
```

In [78]:
```
data['Is Fraud?'].value_counts()
```

Out[78]:
```
Yes    29757
No     24353
Name: Is Fraud?, dtype: int64
```

PREPROCESADO DE DATOS

A continuación se modifica el tipo de dato de las columnas para poder entrenar posteriormente el modelo con datos continuos, se eliminan variables innecesarias y se hacen los remplazamientos necesarios.

In [79]:
```
# Amount:
# El caracter del dólar es innecesario, se debe eliminar y pasar los datos de tipo object a float.
data['Amount'] = data['Amount'].str.replace(r'$', '')
data['Amount'] = pd.to_numeric(data['Amount'])
```

In [80]:
```
# Amount:
# Se opta por pasar a numérico. Eliminando los minutos se simplifica la variable en 24 clases.
data['Time'] = data['Time'].str[:2]
data['Time'] = pd.to_numeric(data['Time'])
```

In [81]:
```
# Use Chip:
# Como hay 3 únicas clases en el dataset depurado (aunque en Kaggle se aprecia el subconjunto "others") se codifican.
data['Use Chip'] = data['Use Chip'].replace({"Swipe Transaction": 0, "Chip Transaction": 1, "Online Transaction": 2})
```

In [82]:
```
# Errors?:
# Para simplificar el dataset se considerarán todos los NaN como 0 (no hay errores) y todos los demás errores como 1.

data['Errors?'].loc[~data['Errors?'].isnull()] = 1  # not nan
data['Errors?'].loc[data['Errors?'].isnull()] = 0   # nan
```

```
C:\Users\Alejandro\anaconda3\lib\site-packages\pandas\core\indexing.py:670: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy (https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy)
  iloc._setitem_with_indexer(indexer, value)
```

In [83]:
```
# Is Fraud?:
# También se binariza la columna, sustituyendo No por 0 y Yes por 1
data['Is Fraud?'].loc[data['Is Fraud?'] == 'No'] = 0
data['Is Fraud?'].loc[data['Is Fraud?'] == 'Yes'] = 1
```

In [84]:
```
# Merchant City y Merchant State:
# Ya que se dispone de Merchant Name, que es numérico, y dada la gran cantidad de clases, se eliminan estas columnas.
data = data.drop(['Merchant City', 'Merchant State'], axis=1)
```

In [85]:
```
# Se guarda el dataset
data.to_csv('purged_data.csv')
```

ANÁLISIS DE DATOS SOBRE EL DATASET PREPROCESADO

In [6]:
```
data = pd.read_csv('purged_data.csv')
# Se pasan los valores a float para que las operaciones matriciales sean posibles
data = data.astype(float)
```

In [89]:
```
# Matriz de dispersión (scatter) y pares de variables
scatter_matrix = pd.plotting.scatter_matrix(
    data,
    figsize  = [10, 10],
    marker   = ".",
    s        = 1,
    diagonal = "kde"
)

for ax in scatter_matrix.ravel():
    ax.set_xlabel(ax.get_xlabel(), fontsize = 10, rotation = 90)
    ax.set_ylabel(ax.get_ylabel(), fontsize = 10, rotation = 0, ha='right')
```

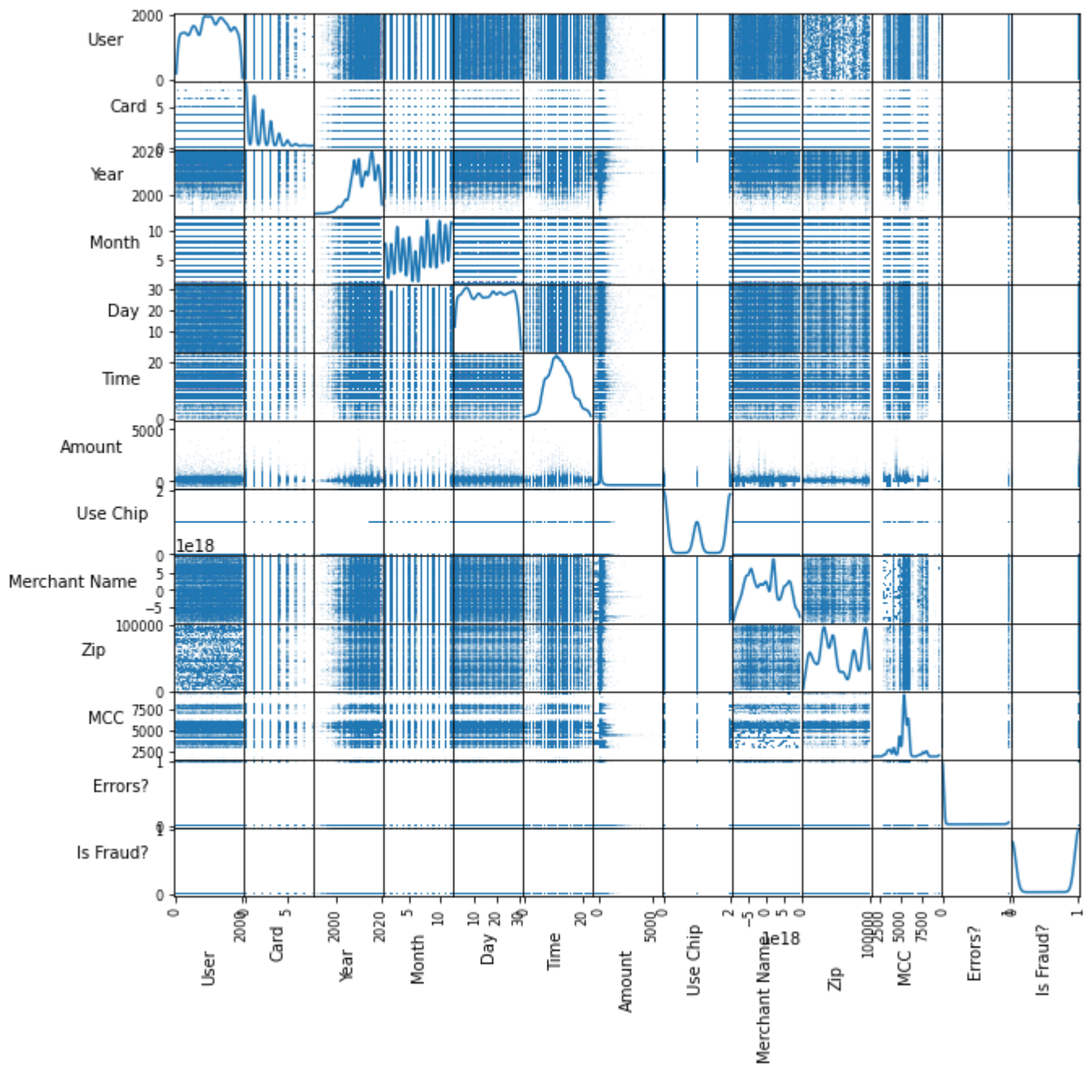

OBSERVACIONES: Son significativas las variables con largas colas, reflejando cierto desbalance de datos.

- Años (Year) - Antes del 2004 habían pocas transferencias, año a partir del cual empieza a subir la tendencia y al canza su punto álgido en torno al 2012.
- Horas (Time) - La mayoría de las transferencias se realizan durante el día.
- Cantidad (Amount) - Aunque pocas, hay transferencias de valores muy elevados, alejadas de la tendencia.

In [103]:
```
# Matriz de correlación
corrMatrix = data.corr()

plt.rcParams['figure.figsize'] = 10, 10
data_matrix = np.round(corrMatrix, 2)
sb.heatmap(data_matrix, annot = True, vmin=-1, vmax=1, square=True)
```

Out[103]: <AxesSubplot:>

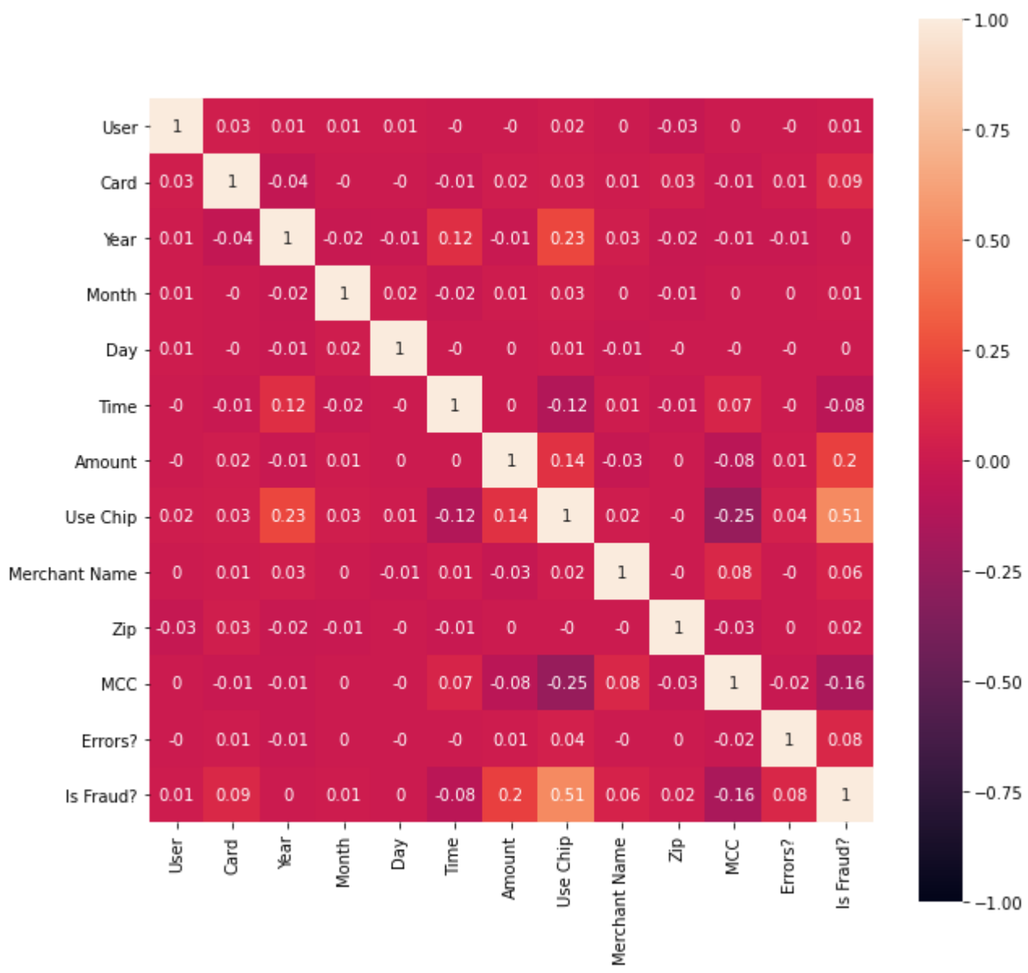

OBSERVACIONES: La mayoría de las variables presentan poca o escasa correlación.

- El uso de tarjetas (chip) está relacionado con el año, quizá debido a la fecha de aparición de las mismas o mayor tendencia en su uso.
- El uso de tarjetas presenta una correlación relevante con los casos de fraude.

COMPARACIÓN DE PARES DE VARIABLES

Este tipo de análisis resulta de utilidad para visualizar situaciones en que NUNCA se han dado anomalías. Dicha comparación anticipa los resultados de las reglas de inferencia.

In [90]:
```
data_in = data.loc[data['Is Fraud?'] == 0]
data_out = data.loc[data['Is Fraud?'] == 1]
```

In [91]:
```
def compare (x,y):
    plt.scatter(data_in[x], data_in[y] )
    plt.scatter(data_out[x], data_out[y], linewidths=5, c='red' )
```

In [92]:
```
compare('Year','Amount')
```


OBSERVACIONES:

- Antes del año 1995 no se aprecian transferencias fraudulentas. En el resto del conjunto de datos se aprecia fraude bajo cualquier cantidad económica.
- Se sobreentiende que el dataset no contiene datos actualizados, al no presentar movimientos fraudulentos en el 2020.
- Los movimientos de mayor importe se realizan en el 2010, posiblemente relacionado con la crisis económica.
- Cabe destacar que en los años 1998, 2000, 2005, 2006, 2007, 2011 y 2012 los movimientos de mayor importe nunca son fraudulentos o no eran detectados.

In [93]:
```
compare('Year','MCC')
```

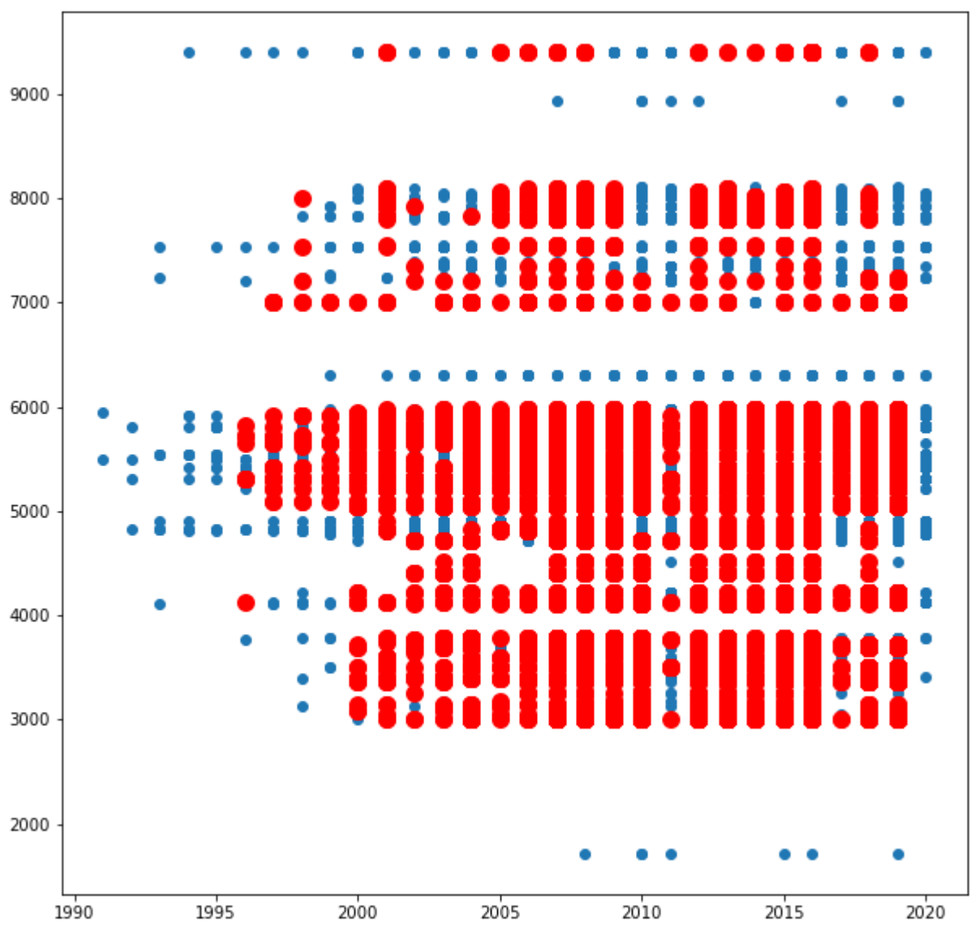

OBSERVACIONES: Hay determinadas categorías de códigos mercantiles (MCC) que nunca son fraudulentas, muy aisladas del resto.

DESARROLLO DEL MODELO DE MACHINE LEARNING

A menudo son útiles métodos de Aprendizaje No Supervisado para resolver problemas de detección de fraude.
Esta solución es interesante cuando no existen ejemplos en que el fraude ha sido detectado, es decir, cuando la única manera de predecir el fraude es a través de consideración de datos anómalos en función de la estructura de los datos, la agrupación, la desviación estándar, la exclusión de los cuartiles o el desbalance de los datos.
En tales casos se emplean métodos como Isolation Forest o LOF (Local Outlier Factor), sin embargo, como en este dataset se dispone de casos etiquetados como fraudulentos se realizará un estudio sobre modelos de Aprendizaje Supervisado.

In [115]:
```
# Se cargan las librerías de Machine Learning
import random
from sklearn.model_selection import train_test_split
from sklearn import metrics

from sklearn.ensemble import RandomForestClassifier
from sklearn import svm
from sklearn.neighbors import KNeighborsClassifier
from sklearn.neural_network import MLPClassifier

from dtreeviz.trees import *
from IPython.core.display import display, HTML
```

In [140]:
```
# Se aislan las variables de entrada 'X' de la variable predictora 'y', la que queremos hallar
X = data.drop('Is Fraud?', axis=1)     # Variables 'X', todas menos la etiqueta 'Is Fraud', la variable predictora
y = data['Is Fraud?']                  # Variable 'y', la etiqueta binaria 'Is Fraud'

# Se convierten las variables a numpy para posteriormente poder aplicar reshape y adaptar su dimensión
X = np.nan_to_num(X)
y = np.nan_to_num(y)

# Finalmente, para evitar overfitting se dividen el conjunto de datos en conjunto de entrenamiento y de test
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=0)
X_test = X_test.reshape(-X_test.shape[0],X_test.shape[1])    #Reshape de X_test para poder introducirlo
```

In [98]:
```
def metricas ():
    print("-------------------------------------------------------")
    print('Métricas de error:')
    print('MAE', metrics.mean_absolute_error(y_test, y_pred))
    print('MSE', metrics.mean_squared_error(y_test, y_pred))
    print('RMSE:', np.sqrt(metrics.mean_squared_error(y_test, y_pred)))
    print('Score:', clf.score(X_test, y_test))
    print("-------------------------------------------------------")
    print('Matriz de Confusión:')
    print(metrics.confusion_matrix(y_test, y_pred))
    print("-------------------------------------------------------")
    print('Report:')
    print(metrics.classification_report(y_test, y_pred))
```

In [99]:
```
print("RANDOM FOREST")
clf = RandomForestClassifier(max_depth=20, n_estimators = 900, criterion = 'gini', random_state=0)
clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)

metricas()
```

```
RANDOM FOREST
-------------------------------------------------------
Métricas de error:
MAE 0.06144890038809832
MSE 0.06144890038809832
RMSE: 0.24788888718153204
Score: 0.9385510996119016
-------------------------------------------------------
Matriz de Confusión:
[[4614  244]
 [ 421 5543]]
-------------------------------------------------------
Report:
              precision    recall  f1-score   support

         0.0       0.92      0.95      0.93      4858
         1.0       0.96      0.93      0.94      5964

    accuracy                           0.94     10822
   macro avg       0.94      0.94      0.94     10822
weighted avg       0.94      0.94      0.94     10822
```

In [100]:
```
print("SVM RBF KERNEL")
clf = svm.SVC(kernel="rbf")
clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)

metricas()
```

```
SVM RBF KERNEL
-------------------------------------------------------
Métricas de error:
MAE 0.4358713731288117
MSE 0.4358713731288117
RMSE: 0.660205553694311
Score: 0.5641286268711884
-------------------------------------------------------
Matriz de Confusión:
[[1319 3539]
 [1178 4786]]
-------------------------------------------------------
Report:
              precision    recall  f1-score   support

         0.0       0.53      0.27      0.36      4858
         1.0       0.57      0.80      0.67      5964

    accuracy                           0.56     10822
   macro avg       0.55      0.54      0.51     10822
weighted avg       0.55      0.56      0.53     10822
```

In [101]:
```
print("K NEAREST NEIGHBORS")
clf = KNeighborsClassifier(n_neighbors=3)
clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)

metricas()
```

```
K NEAREST NEIGHBORS
-------------------------------------------------------
Métricas de error:
MAE 0.11042321197560524
MSE 0.11042321197560524
RMSE: 0.3322998825994455
Score: 0.8895767880243948
-------------------------------------------------------
Matriz de Confusión:
[[4321  537]
 [ 658 5306]]
-------------------------------------------------------
Report:
              precision    recall  f1-score   support

         0.0       0.87      0.89      0.88      4858
         1.0       0.91      0.89      0.90      5964

    accuracy                           0.89     10822
   macro avg       0.89      0.89      0.89     10822
weighted avg       0.89      0.89      0.89     10822
```

In [102]:
```
print("MULTI LAYER PERCEPTRON (2 capas ocultas)")
clf = MLPClassifier(random_state=1, max_iter=500)
clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)

metricas()
```

```
MULTI LAYER PERCEPTRON (2 capas ocultas)
--------------------------------------------------------
Métricas de error:
MAE 0.49574939937165036
MSE 0.49574939937165036
RMSE: 0.7040947374974836
Score: 0.5042506006283497
--------------------------------------------------------
Matriz de Confusión:
[[2522 2336]
 [3029 2935]]
--------------------------------------------------------
Report:
              precision    recall  f1-score   support

         0.0       0.45      0.52      0.48      4858
         1.0       0.56      0.49      0.52      5964

    accuracy                           0.50     10822
   macro avg       0.51      0.51      0.50     10822
weighted avg       0.51      0.50      0.51     10822
```

OBSERVACIONES: El modelo que presenta un mejor rendimiento es Random Forest, con un accuracy de 0.94 y las métricas de error más bajas. K nearest neighbours también resulta en un modelo con pocos FP y FN, pero sigue clasificando mejor Random Forest. Cabe destacar que para esta prueba no se han realizado métodos de búsqueda de hiperparámetros que podrían haber mejorado el rendimiento de los modelos (como búsqueda por rejilla o búsqueda aleatoria).

REGLAS DE INFERENCIA

Puede resultar útil extraer reglas de inferencia de modelos caja blanca, como los árboles de decisión o la regresión lineal. En este caso, aprovechando que Random Forest es el modelo que resulta más efectivo entre los testados, se estudian las reglas de inferencia de uno de los árboles que lo componen.

In [ ]:
```
clf = RandomForestClassifier(max_depth=2, random_state=0)
clf.fit(X, y)

feature_names = list(data.drop('Is Fraud?', axis=1).columns)

viz = dtreeviz(clf.estimators_[0],
               X,
               y,
               target_name='Is Fraud?',
               feature_names = feature_names,
               class_names=["Not Fraud", "Fraud"],
               scale=2,
               histtype= 'barstacked')
viz
```

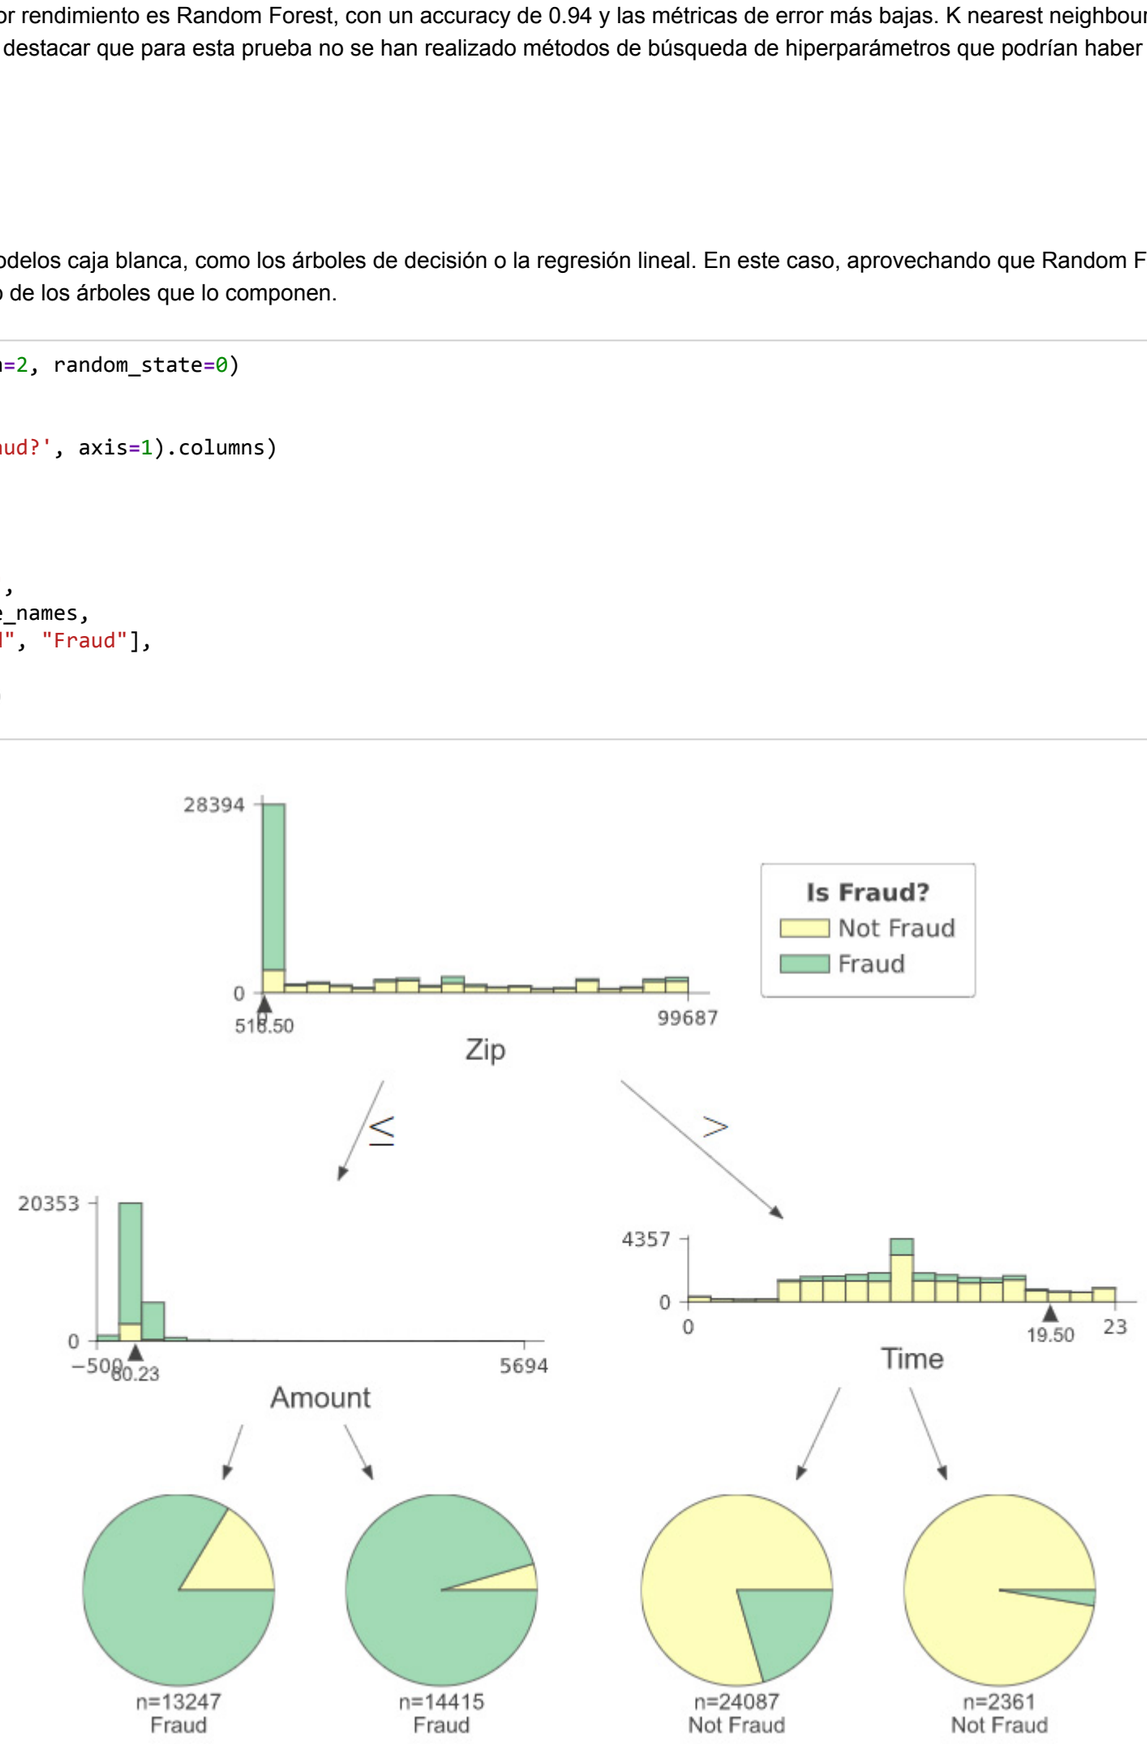

OBSERVACIONES: La variable Zip resulta muy relevante a la hora de clasificar fraude, siendo los valores por debajo de 510 un gran estimador de fraude. Además de las observaciones emitidas en apartados anteriores ('comparación de pares de variables') las reglas de inferencia resultan útiles para aproximar la pronosticación de casos novedosos de manera sencilla.